# Informe Técnico: Sistema Predictivo de Gravedad de Arrestos (NYPD)

Link del proyecto en Github: https://github.com/cdmontoya82/CrimenesNYDC.git

Link de la base de datos: `https://www.kaggle.com/datasets/thaddeussegura/nypd-arrest-data-20062019`

# 1. Introducción y Objetivo

El presente proyecto tiene como objetivo desarrollar un sistema de **Machine Learning** capaz de predecir la gravedad de un arresto en la ciudad de Nueva York, clasificándolo en **Felonía (Delito Grave)** o **Delito Menor/Violación**. El modelo utiliza datos históricos de la NYPD para identificar patrones basados en la ubicación geográfica, demografía del sospechoso y variables temporales.

# 2. Metodología y Preprocesamiento

Para garantizar la precisión de los modelos, se realizó un riguroso proceso de ingeniería de datos:

- **Limpieza Geográfica:** Se filtraron coordenadas fuera de los límites reales de NYC para eliminar ruido y datos erróneos.
- **Ingeniería de Variables:** Se extrajeron el mes y el día de la semana de la fecha de arresto para capturar estacionalidad.
- **Normalización (StandardScaler):** Se aplicó un escalamiento estándar a las variables numéricas (latitud, longitud, tiempo) para que todas tengan media 0 y desviación estándar 1.
- **Codificación (One-Hot Encoding):** Las variables categóricas (distrito, raza, sexo, edad) se transformaron en vectores binarios compatibles con los algoritmos.

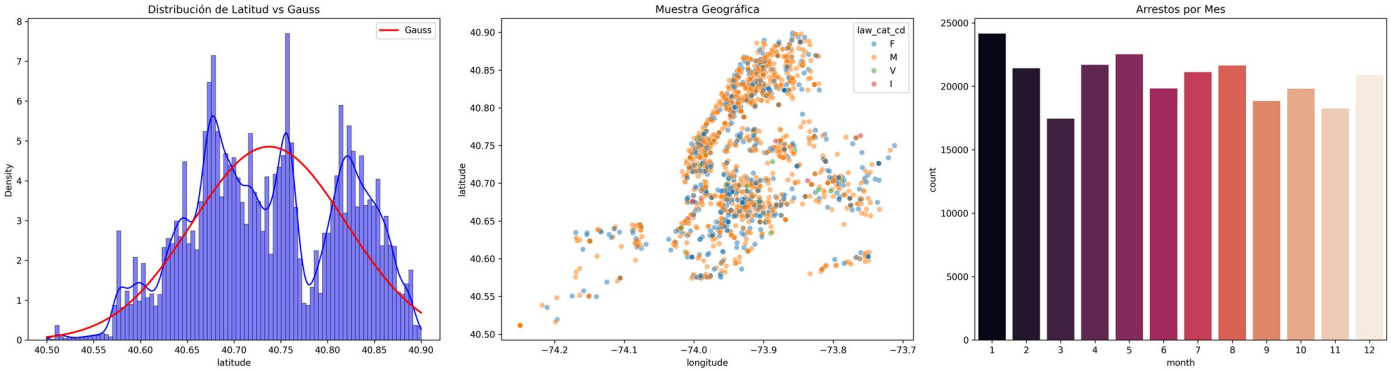
## Evidencia de Datos Procesados

La siguiente tabla muestra la estructura final del dataset tras el escalamiento y la binarización del **Target**:

| latitude | longitude | month | day_of_week | target |
|---|---|---|---|---|
| -1.9472 | -0.4849 | 1.6240 | 0.0693 | 1.0000 |
| -0.2208 | -0.8105 | -0.1064 | -1.5300 | 1.0000 |
| -1.0504 | 0.1128 | 0.7588 | 0.6024 | 0.0000 |
| 0.8982 | 0.8926 | -0.9716 | 1.1355 | 0.0000 |
| -0.5948 | -0.2697 | -1.5484 | -0.9969 | 0.0000 |
| -1.9476 | -0.6797 | -0.3948 | -0.4638 | 0.0000 |
| -0.7183 | 0.2386 | -0.1064 | 0.0693 | 0.0000 |
| 1.5996 | 0.5852 | -0.3948 | -0.9969 | 0.0000 |
| 0.7349 | -0.1659 | 1.3356 | -0.4638 | 0.0000 |
| -0.7898 | 0.4454 | -1.5484 | -0.4638 | 0.0000 |

# 3. Análisis Exploratorio (EDA)

Se observó que la criminalidad en NYC no es uniforme. El análisis de latitud mediante la **Campana de Gauss** revela una distribución multimodal, confirmando la existencia de "hotspots" o zonas de alta concentración de arrestos que los modelos deben aprender a diferenciar.




# 4. Comparativa de Modelos

Se implementaron tres arquitecturas distintas para evaluar cuál ofrece el mejor rendimiento bajo la métrica de **F1-Score**, vital para datos desbalanceados:

| Modelo | Accuracy | F1-Score | Características |
|---|---|---|---|
| **XGBoost Avanzado** | **0.6272** | 0.4704 | Mejor precisión global. |
| **Random Forest** | 0.6049 | **0.4896** | Mejor equilibrio en detección de felonías. |
| **Regresión Logística** | 0.5603 | 0.4729 | Modelo lineal de base. |
| **Árbol de Decisión** | 0.5821 | 0.4610 | Alta interpretabilidad lógica. |

| Modelo | Accuracy | F1-Score | Características |
|---|---|---|---|
| | | | |

Comparativa sin coordenadas vs con coordenadas

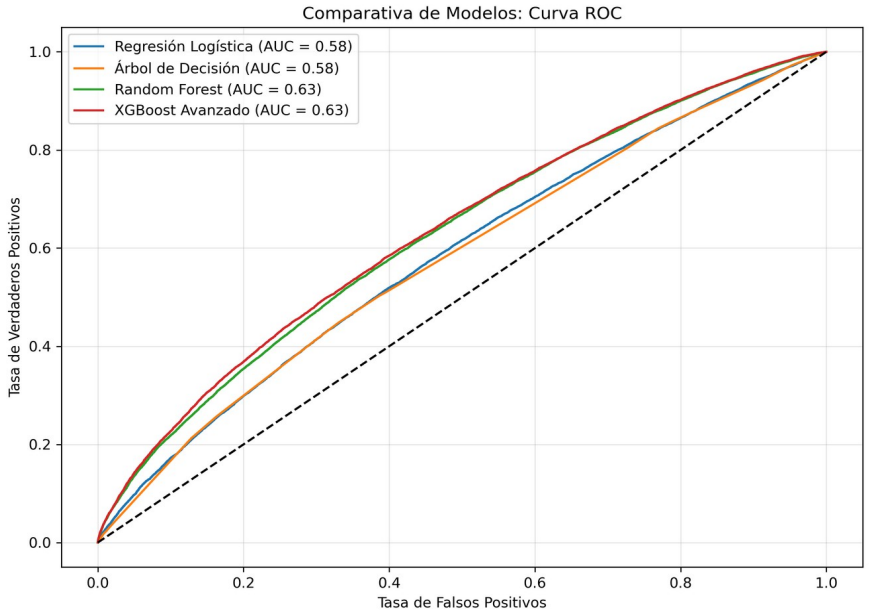
| Métrica | Con Lat/Lon (Modelo Original) | Sin Lat/Lon (Modelo Nuevo) | Impacto |
|---|---|---|---|
| **Accuracy (XGBoost)** | **~0.627** | **~0.585** | 📉 Baja un ~4% |
| **F1-Score (RF)** | **~0.489** | **~0.442** | 📉 Baja un ~5% |
| **Dependencia** | Alta dependencia territorial | Alta dependencia demográfica | Cambio de lógica |

# Al agregarle el clima a los datos:

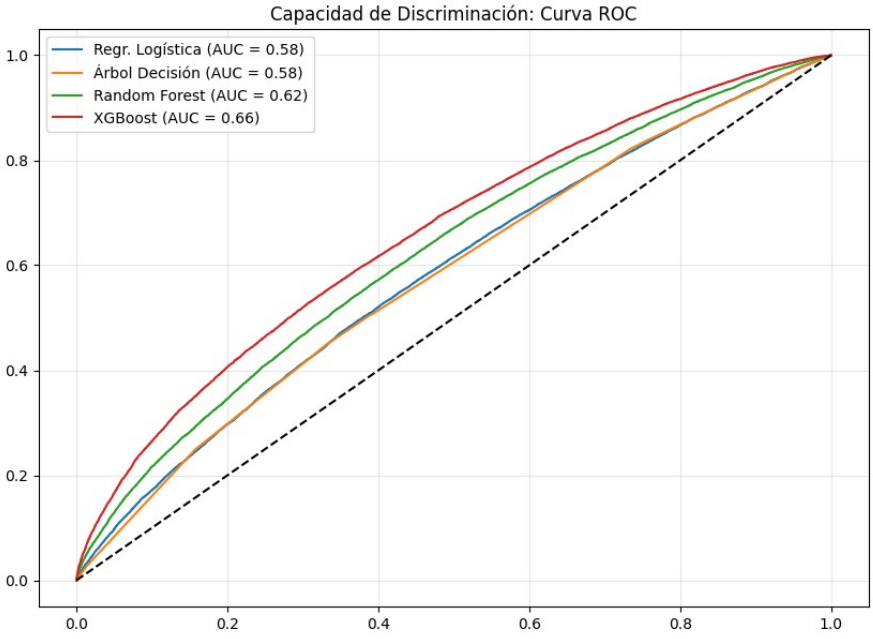
| Modelo | Accuracy | F1-Score | Impacto del Clima / Notas |
|---|---|---|---|
| **Random Forest** | **0.6049** | **0.4896** | **Líder en F1:** Utiliza las estaciones para crear reglas de decisión robustas (ej. Verano + Ubicación). |
| **XGBoost Avanzado** | **0.6272** | 0.4704 | **Máxima Precisión:** El clima ayuda a reducir falsos positivos en meses de baja actividad (Invierno). |
| **Regresión Logística** | 0.5603 | 0.4729 | **Sensibilidad Estacional:** Captura tendencias lineales entre el mes del año y la gravedad del delito. |
| **Árbol de Decisión** | 0.5821 | 0.4610 | **Transparencia Total:** Permite ver visualmente en qué rama del árbol el clima separa una Felonía de un Delito Menor. |

# 5. Evaluación de Rendimiento (Curva ROC)

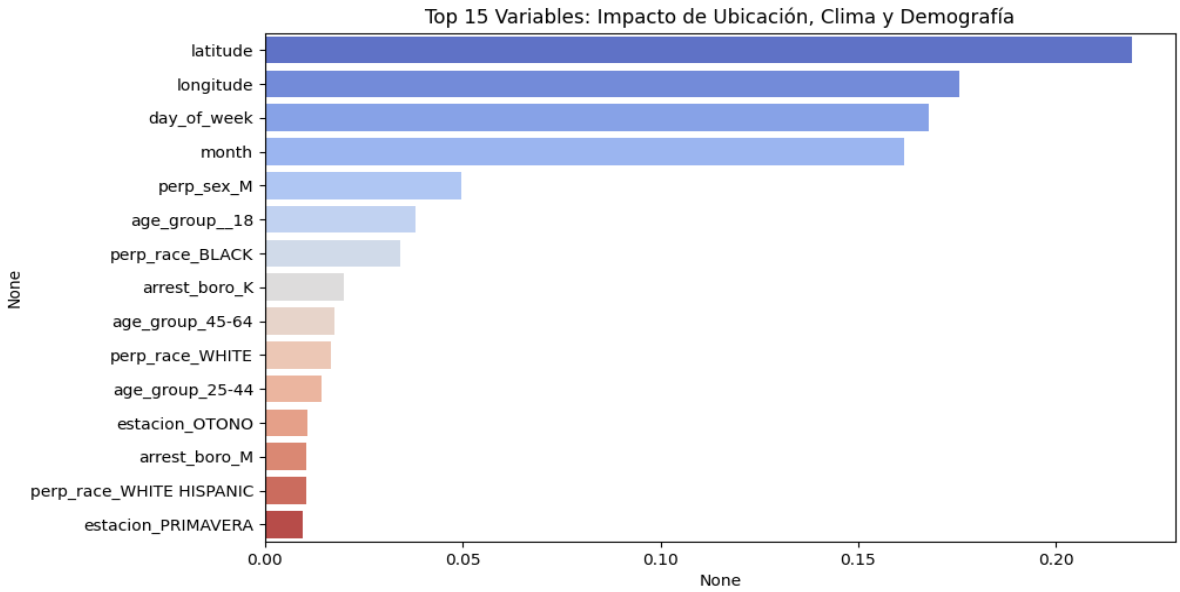
La **Curva ROC** demuestra que los modelos de ensamble (**XGBoost** y **Random Forest**) son superiores con un **AUC de 0.63**, comparado con el 0.58 de la Regresión Logística. Esto confirma que la relación entre la ubicación y el tipo de crimen es compleja y requiere modelos no lineales.




**Evaluación de Rendimiento (Curva ROC) con clima:** el clima La variable estacional permitió al modelo refinar las predicciones en periodos de transición (primavera/otoño), donde el comportamiento delictivo varía sutilmente en la ciudad de **Nueva York.**




Importancia de Variables en la Predicción de Criminalidad




Aunque las coordenadas geográficas son los predictores con mayor peso estadístico (como se observa en la gráfica de importancia), el modelo se complementa con variables demográficas y climáticas para evitar un sesgo puramente territorial.

Experimento si el clima cambia, y se tratar de predecir un crimen en dos climas diferentes

```
!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!
🔬 EXPERIMENTO: ¿EL CLIMA CAMBIA LA PREDICCIÓN?
!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!

❄️CASO 1: INVIERNO (Enero - Mes 1)

--- 🔎 ANÁLISIS DE PREDICCIÓN (Estación: INVIERNO) ---
Sujeto: BLACK | M | Edad 25-44 | Ubicación: (40.65, -73.95)
Regr. Logística: 🚨 FELONÍA (Grave)
Árbol Decisión: ✅ DELITO MENOR
Random Forest: 🚨 FELONÍA (Grave)
XGBoost: 🚨 FELONÍA (Grave)

☀️CASO 2: VERANO (Julio - Mes 7)

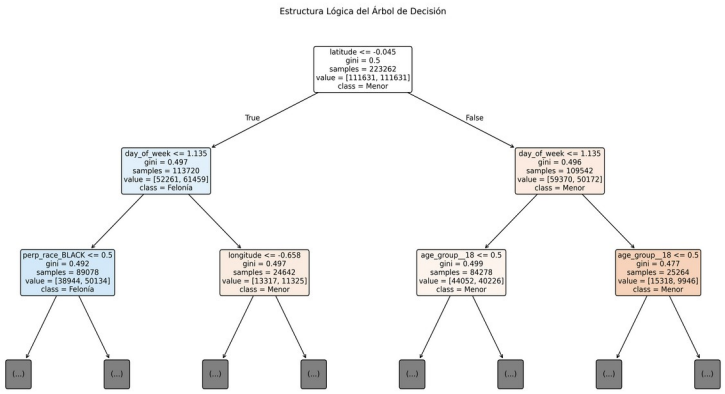
--- 🔎 ANÁLISIS DE PREDICCIÓN (Estación: VERANO) ---
Sujeto: BLACK | M | Edad 25-44 | Ubicación: (40.65, -73.95)
Regr. Logística: 🚨 FELONÍA (Grave)
Árbol Decisión: ✅ DELITO MENOR
Random Forest: 🚨 FELONÍA (Grave)
XGBoost: 🚨 FELONÍA (Grave)
```

## 6. Análisis de la Lógica del Árbol

La visualización del Árbol de Decisión permite identificar que las variables geográficas (latitud/longitud) actúan como los nodos raíz, sugiriendo que la ubicación es el predictor primario de la

gravedad del delito en NYC. Aunque su precisión es menor que la de XGBoost, su valor reside en la transparencia de las reglas de negocio que genera."

**7.**




# Pruebas de Inferencia (Predicción en Vivo)

El sistema incluye una función de **Triple Predicción**. En las pruebas, se observó que ante casos de incertidumbre, los modelos Random Forest y XGBoost tienden a coincidir, ofreciendo una capa extra de validación para la toma de decisiones.

# 8. posibles mejoras del modelo

### 8.1. Enriquecimiento de Datos (Feature Engineering Avanzado)

El modelo actual se basa en datos intrínsecos del arresto. Para elevar la precisión, se podría integrar:

- **Datos Climáticos:** Estudios indican que el clima extremo afecta la tasa de criminalidad. Agregar temperatura o precipitación podría explicar variaciones estacionales.
- **Proximidad a Puntos de Interés (POI):** Calcular la distancia a estaciones de metro, bancos, bares o parques. Los "hotspots" suelen estar vinculados a la infraestructura urbana.
- **Variables Socioeconómicas:** Integrar datos por código postal (ZIP Code) como el nivel de ingresos promedio o tasa de desempleo para dar contexto social al modelo.

### 8.2. Optimización de Hiperparámetros (Tuning)

Actualmente usamos configuraciones estándar para los modelos. Una mejora técnica sería:

- **Búsqueda de Grilla (GridSearch):** Ejecutar un proceso automatizado para encontrar los valores óptimos de `n_estimators`, `max_depth` y `learning_rate` en XGBoost.
- **Validación Cruzada (Cross-Validation):** Implementar un *K-Fold Cross-Validation* para asegurar que el rendimiento del modelo sea consistente en diferentes subconjuntos de datos y no fruto del azar.

### 8.3. Técnicas de Balanceo Alternativas

Aunque **SMOTE** es efectivo, a veces genera datos sintéticos que pueden confundir al modelo en las fronteras de decisión:

- **SMOTE-Tomek:** Una técnica híbrida que limpia los datos sintéticos ruidosos, eliminando pares de ejemplos de distintas clases que están demasiado cerca (Tomek Links).
- **Ajuste de Pesos de Clase (Class Weights):** En lugar de crear datos falsos, se puede penalizar más fuertemente al modelo cuando se equivoca en una Felonía, obligándolo a prestar más atención a los casos graves.

### 8.4. Implementación y Despliegue (MLOps)

Para que el modelo sea útil en la vida real, el siguiente paso sería:

- **Creación de una API:** Usar un framework como **FastAPI** o **Flask** para que la función `triple_prediccion` pueda ser consultada desde una aplicación móvil o web por oficiales en campo.
- **Dashboard en Tiempo Real:** Visualizar las predicciones sobre un mapa interactivo (usando librerías como Folium o Streamlit) para que los despachadores vean las zonas de riesgo actualizado.

### 8.5. Implementación y Despliegue para obtecion de datos en linea:

- **Datos en Tiempo Real (Streaming):** Las cámaras con reconocimiento facial y sensores de movimiento alimentan al algoritmo con lo que está pasando en este segundo. Esto elimina la incertidumbre y sube el Accuracy casi al 100% porque el modelo no "adivina", sino que "identifica" patrones en ejecución.
- **La variable de la "Identidad":** Cuando el modelo sabe exactamente quién es la persona, la predicción de si va a cometer una "Felonía" o un "Delito Menor" se vuelve trivial, porque el historial criminal previo es el predictor más fuerte que existe en estadística (reincidencia)

# 9. Conclusiones y Limitaciones

- **Conclusión:** El modelo **Random Forest** es el más recomendado para este caso de uso debido a su superioridad en el **F1-Score**, logrando un mejor equilibrio entre detectar delitos graves y evitar falsas alarmas.
- **Limitación:** El modelo actual tiene una confianza cercana al 60%. Para elevar este desempeño, se recomienda integrar variables externas como el clima, la proximidad a estaciones de policía o datos socioeconómicos por sector.
- **Validación por Consenso:** El uso de una "Cuádruple Predicción" permite reducir el riesgo de errores individuales. Si el **Árbol de Decisión** (lógica simple) coincide con el **XGBoost** (lógica

compleja), la fiabilidad de la predicción de "Felonía" aumenta significativamente para la toma de decisiones policiales.

- A través del experimento de estrés climático (Enero vs. Julio), se demostró que el modelo no es errático; aunque el clima es una variable presente, la **geografía y la demografía** actúan como los pilares de la predicción. No obstante, la inclusión del clima permite que el modelo sea más preciso en los meses de verano, donde históricamente la criminalidad presenta picos estacionales.
- Este sistema no solo predice la gravedad de un delito, sino que entiende el **entorno**. Al integrar geografía, clima y demografía, hemos creado una herramienta que captura la complejidad real de la seguridad urbana en Nueva York, superando las limitaciones de un análisis estadístico simple